Углублённое программирование на C++

Многопоточность

Кухтичев Антон

education

17 июня 2024 года

Напоминание отметиться на портале

и оставить отзыв после лекции

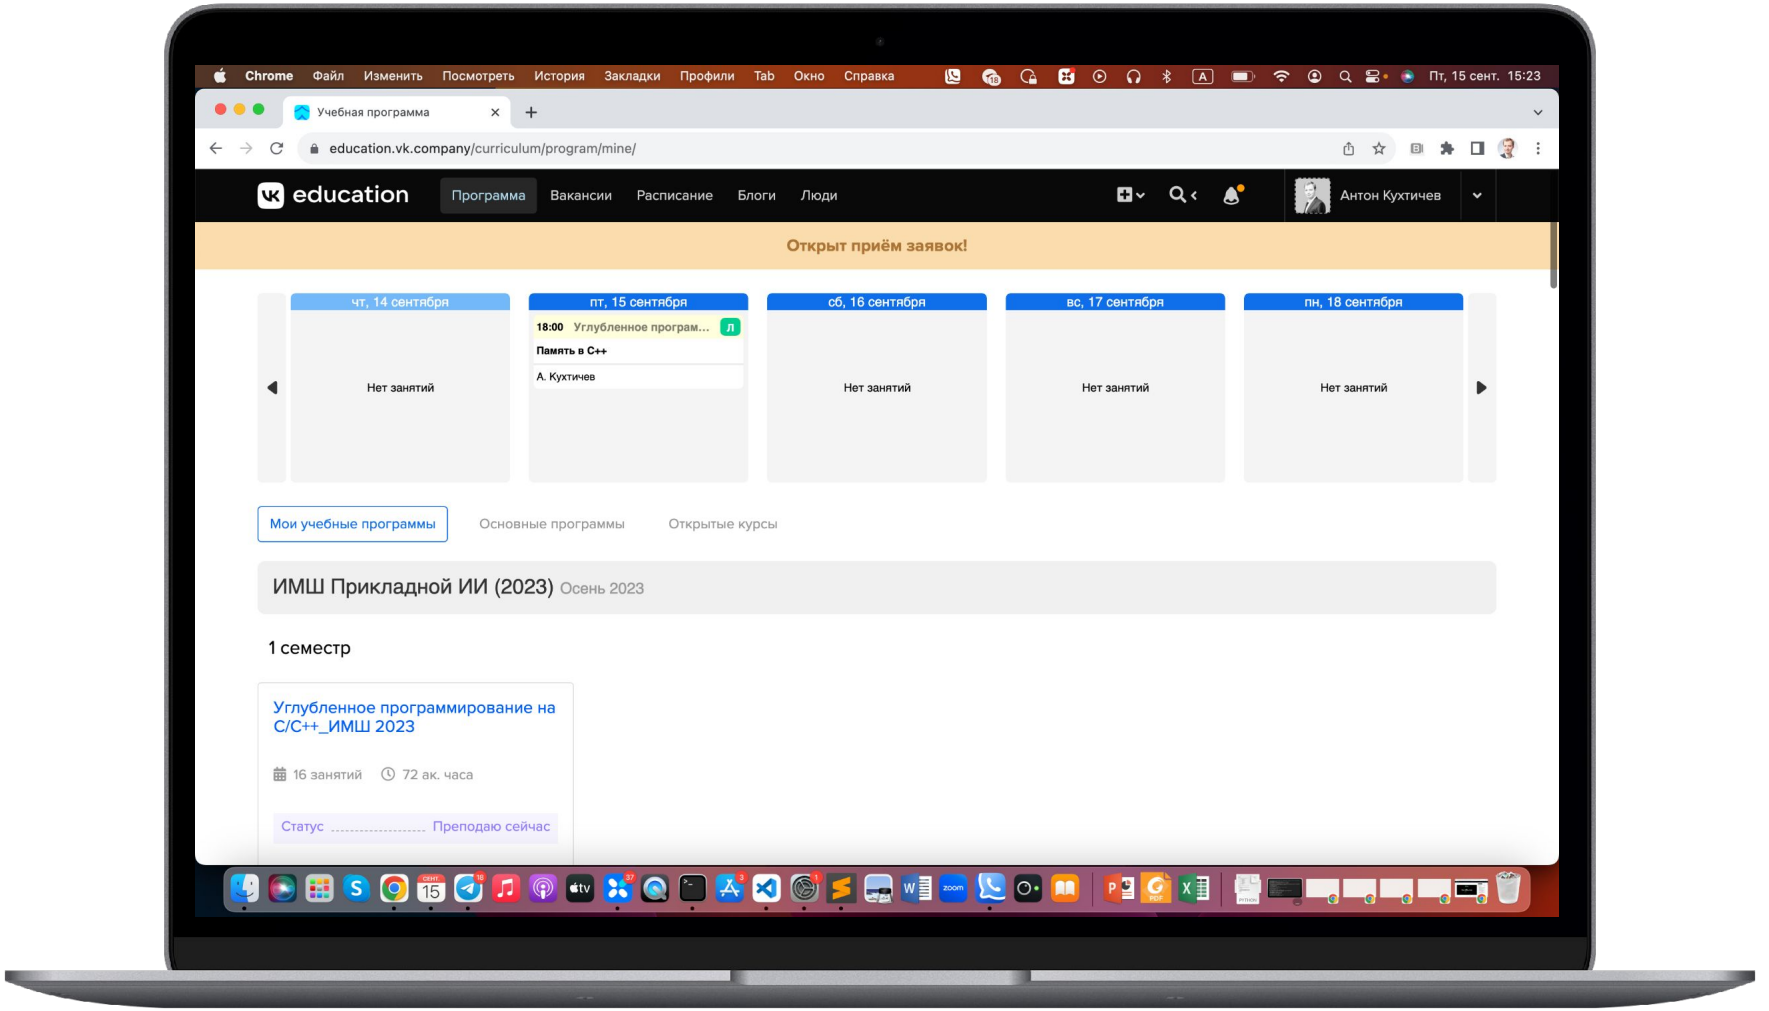

Содержание занятия

- Многопоточность (multithreading)
- std::thread
- std::atomic
- Исключения в потоке
- Гонки (race condition)
- Взаимоблокировки (deadlock)

Энтони Уильямс. C++. Практика многопоточного программирования

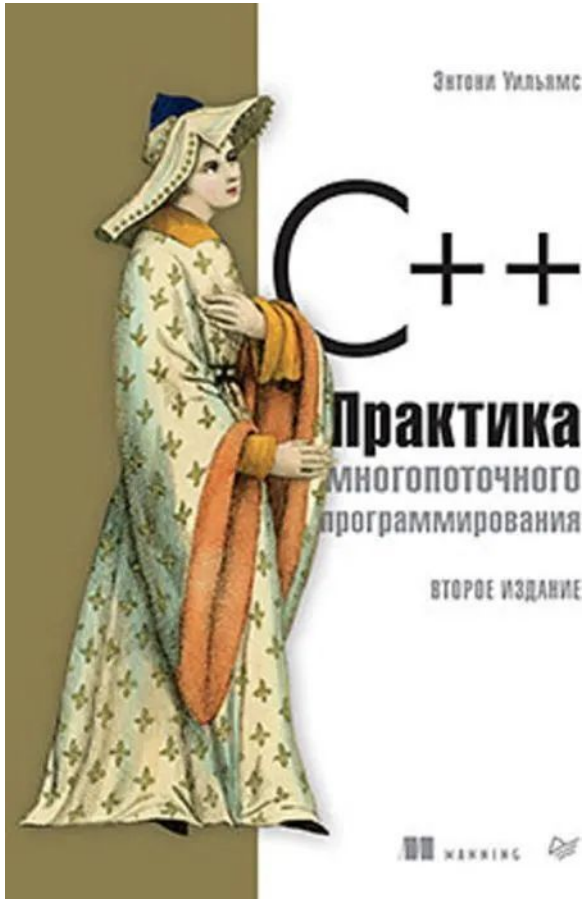

Многопоточность (multithreading)

Многопоточность (multithreading)

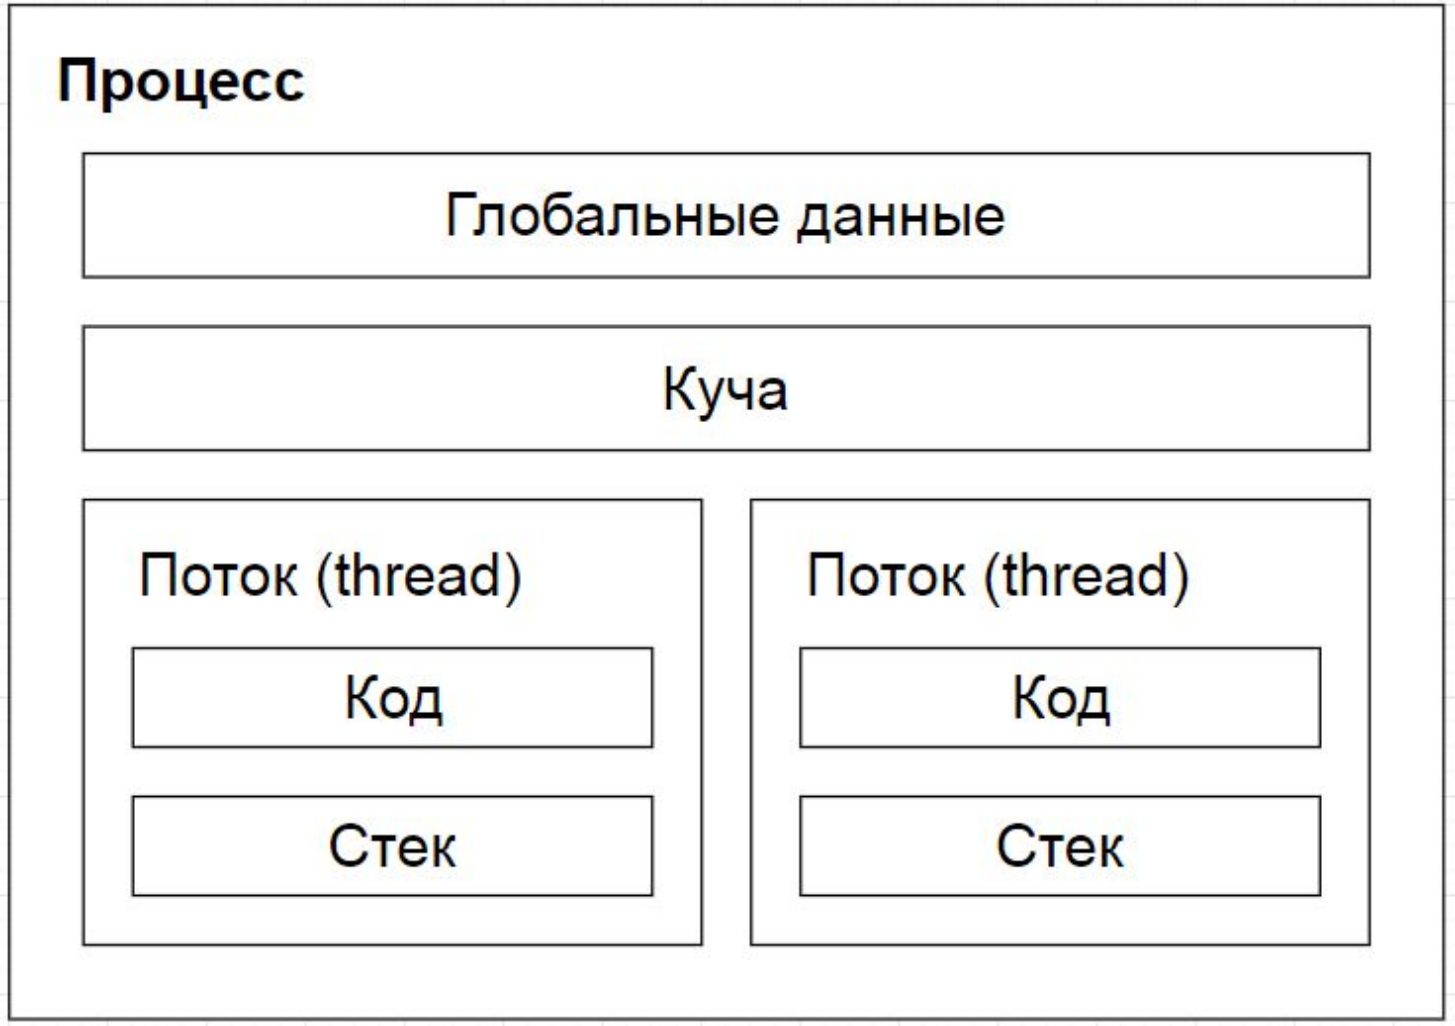

Многопоточность (multithreading)

Многозадачность – возможность параллельной (или псевдопараллельной) обработки нескольких задач.

- Многозадачность основанная на прерываниях планировщика
- Кооперативная многозадачность – выполняемый код должен уступать процессорное время для других

Чтобы определить количество задач, которые реально можно выполнять в многопоточном режиме на том или ином компьютере, используется функция `std::thread::hardware_concurrency()`.

Многопоточность (multithreading)

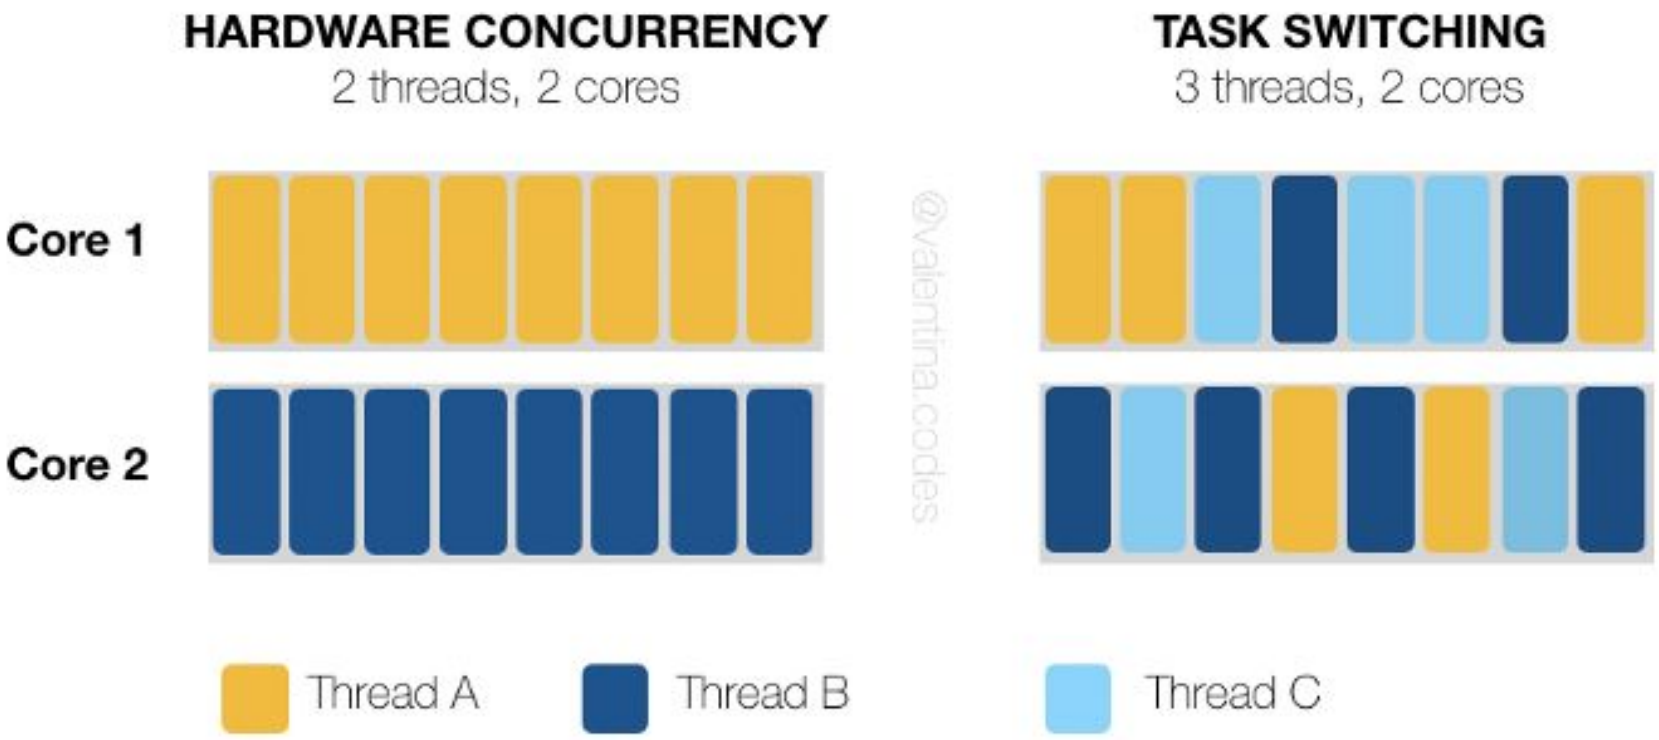

std::thread

std::thread

- Заголовочный файл `#include <thread>`
- `std::thread t(callable_object, arg1, arg2, ...)`
- `t` вызывает `callable_object(arg1, arg2, ...)`
- Аргументы по умолчанию копируются, чтобы избежать копирование нужно использовать `std::ref()`;
- Объект потока можно переместить, но нельзя копировать!

std::thread

- Если основной поток завершает выполнение, все второстепенные сразу останавливаются без возможности восстановления (`std::terminate`). Чтобы этого не допустить, у родительского потока имеются два варианта для каждого порождённого:
  - Блокирует и ждёт завершения порождённого потока, вызывая на нём метод `join`.
  - Прямо объявляет, что порождённый поток может продолжить выполнение даже после завершения родительского, используя метод `detach`.

std::this_thread

```
// идентификатор потока
const std::thread::id id =
    std::this_thread::get_id();

// указание планировщику снять поток с выполнения до следующего раза
std::this_thread::yield();

// усыпить поток на указанное время
std::this_thread::sleep_for(
    std::chrono::seconds(1))
```

`std::thread::id` можно сравнить, можно вывести в поток вывода.

thread_local

Хранилище уровня потока (C++11).

- Создается, когда запускается поток
- Уничтожается, когда поток завершает работу
- Для каждого потока своё

```
static thread_local std::map<std::string, int> threadCache;
```

std::future

Ожидание выполнения асинхронной задачи.

```
std::future<int> f =
    std::async(std::launch::async, []() { return 5 });
...
const int result = f.get();

auto f =
    std::async(std::launch::async, []() { return 5 });
...
f.wait();
```

std::async

Поведение `std::async`, зависит от переданных флагов следующим образом:

- `launch::async` – будет создан объект класса thread, с функцией и её аргументами в качестве аргументов нового потока;
- `launch::deferred` – никакого асинхронного вызова не произойдёт. Вместо исполнения функции в новом потоке, она, вместе с аргументами, будет сохранена в future, чтобы быть вызванными позже. Это поведение есть ни что иное, как отложенный вызов процедуры;
- `launch::async | launch::deferred` – в этом случае будет выбрано одно из двух поведений описанных выше. Какое из двух? Неизвестно и зависит от реализации.

1. Скотт Мейерс. Эффективный и современный C++. 7.2 Если важна асинхронность, указывайте std::launch::async

std::future

- `T get()` или `T& get()`

  Поток вызвавший get блокируется до вычисления значения

- `void wait() const;`

  просто подождать появления значения без его непосредственного получения

- ```
  template<class Rep, class Period>
  std::future_status wait_for(const
  std::chrono::duration<Rep,Period>& timeout_duration) const;
  ```

- ```
  template< class Clock, class Duration >
  std::future_status wait_until(const
  std::chrono::time_point<Clock,Duration>& timeout_time) const;
  ```

std::future

```
auto f =
    std::async(std::launch::async, []() { return 5 });

auto status = f.wait_for(std::chrono::seconds(1));

if (status == std::future_status::deferred)
    std::cout << "задача еще не стартовала";
else if (status == std::future_status::timeout)
    std::cout << "результата не дождались";
else if (status == std::future_status::ready)
    std::cout << "все готово";
```

std::packaged_task

```
std::future<int> runTask()
{
    std::packaged_task<int()> task([]()
    {
        return 1;
    });

    auto future = task.get_future();

    std::thread thread(std::move(task));
    thread.detach();

    return future;
}

auto task = runTask();
task.get();
```

std::promise

Позволяет вернуть результат работы из потока.

```
#include <future>
std::future<int> runTask()
{
    std::promise<int> promise;
    std::future<int> future = promise.get_future();

    auto task = [](std::promise<int>&& p)
    {
        p.set_value(1);
    };

    std::thread thread(task, std::move(promise));
    thread.detach();

    return future;
}
```

std::atomic

Барьеры в памяти

```
bool ready = false;
int data = 0;

int foo() { return 5; }

void produce()
{
    data = foo();
    ready = true;
}

void consume()
{
    while (!ready) ;
    assert(data == 5); // не всегда
}
```

Барьеры в памяти

```
void produce()
{
    // data = foo();
    // Ooo, это долго, выполню пока это:
    ready = true;
    // А теперь остальное:
    data = foo();
}

void consume()
{
    while (!ready) // ждем
        ;
    assert(data == 5); // не всегда
}
```

Барьеры в памяти

Барьер – инструкция состоящая из указания двух типов операций работы с памятью:

Барьер гарантирует, что до барьера все операции работы с памятью типа X будут выполнены, а операции типа Y после барьера не начнут выполняться.

Операций работы с памятью две:

1. Чтение (Load)
2. Запись (Store)

Барьеры в памяти

```
#include <atomic>

enum memory_order
{
    memory_order_relaxed,
    memory_order_consume,
    memory_order_acquire, // <-- acquire
    memory_order_release, // <-- release
    memory_order_acq_rel,
    memory_order_seq_cst  // <-- default
};

void atomic_thread_fence(std::memory_order order) noexcept;
```

1. Энтони Уильямс. C++. Практика многопоточного программирования. 5.3.3 Упорядочение доступа к памяти для атомарных операций.

Барьеры в памяти

```
void produce()
{
    data = foo();
    // Перед тем, как делать Store-операции
    // завершить все операции до барьера
    std::atomic_thread_fence(std::memory_order_release);
    ready = true;
}
```

Барьеры в памяти

```
produce():
    call    foo()
    mov     DWORD PTR data[rip], eax
    mfence
    mov     BYTE PTR ready[rip], 1
    ret
```

std::atomic

```
std::atomic<T> value;

T load(std::memory_order
    order = std::memory_order_seq_cst) const noexcept;

void store(T value, std::memory_order
    order = std::memory_order_seq_cst) noexcept;
```

std::atomic

```
std::atomic<int> i = 5;

i.store(3);
int j = i.load();

++i;
int k = i;
```

Исключения в потоке

Исключения в потоке

```
void foo()
{
    throw std::runtime_error();
}

std::thread t1(foo);
t1.join();
```

В этом случае поток просто завершиться, об исключении мы не узнаем.

Исключения в потоке

```
auto f = std::async(std::launch::async, foo);

try
{
    f.get();
}
catch (const std::runtime_error& error)
{
    // Получили ошибку
}
```

Исключения в потоке

```
auto task = ([](std::promise<int>&& p)
{
    try
    {
        foo();
    }
    catch (...)
    {
        p.set_exception(std::current_exception());
    }
}
```

Гонки
(race condition)

Гонки (race condition)

```
int i = 17;

void plus1()
{
    i += 1;
}

std::thread t1(plus1);
std::thread t2(plus1);

t1.join();
t2.join();

std::cout << i; // ???
```

Гонки (race condition)

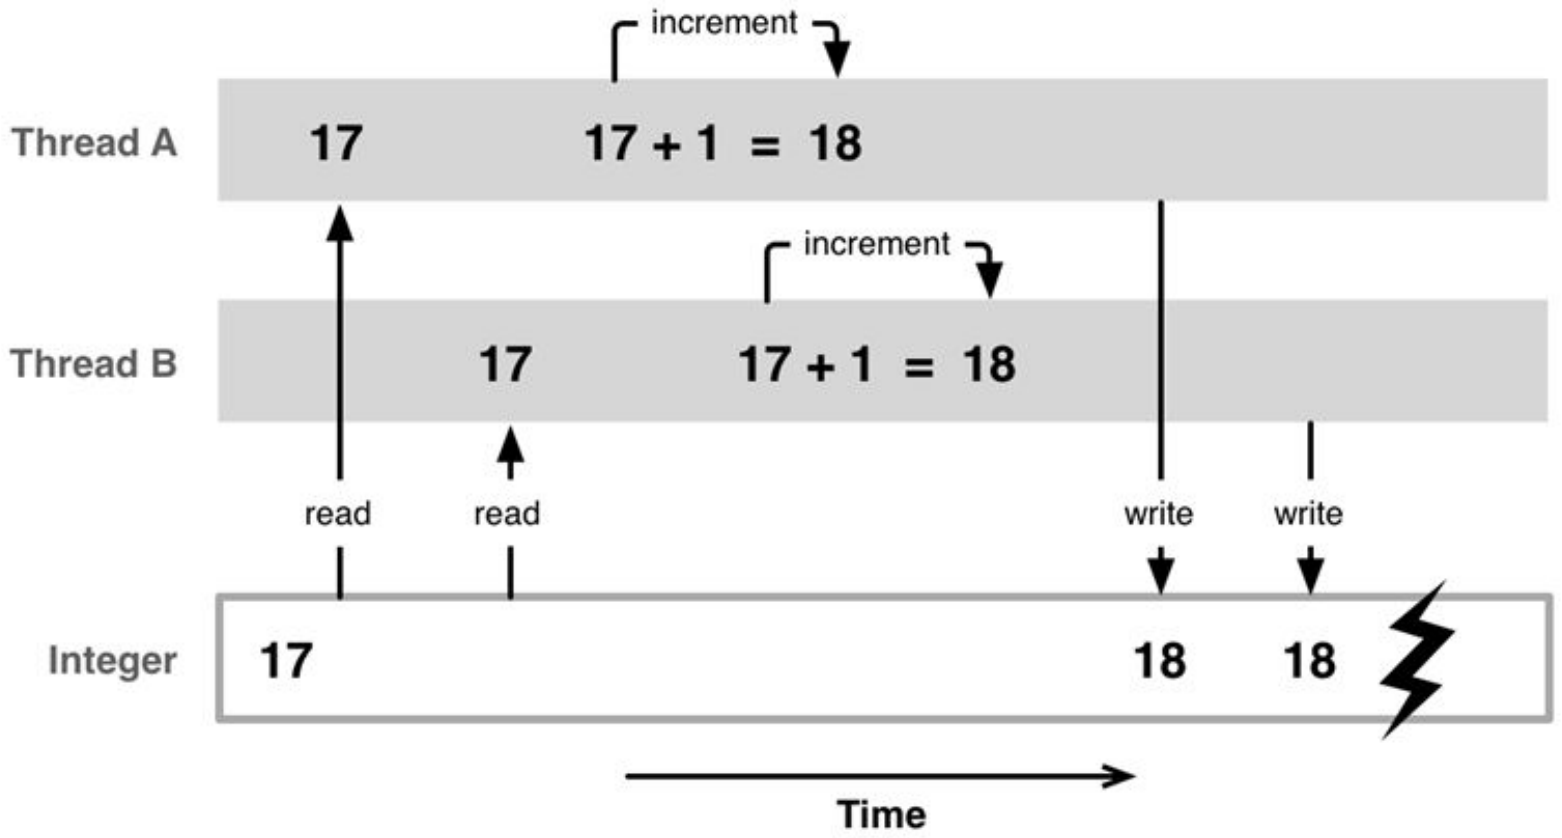

Средства синхронизации

1. Атомарные операции;
2. Спинлоки (spinlock);
3. Семафоры (semaphore);
4. Мютексы (mutex);
5. Условные переменные (condition variable);
6. Критические секции (critical section);
7. Высокоуровневые очереди и планировщики.

Спинлоки (spinlock)

База – все блокировки в ядре ОС основаны на спинлоках, которые в свою очередь используют атомарные операции, без этого реализовать безопасное межпроцессорное взаимодействие невозможно.

Спинлоки (spinlock)

```
int atomicExchange(int* old, int newValue);

// *lock == 0 - никем не захвачен
void spinlock(volatile int* lock)
{
    while (true)
    {
        if (*lock == 0)
        {
            const int old = atomicExchange(lock, 1);
            if (old == 0)
            {
                return;
            }
        }
    }
}
```

Семафоры (semaphore)

Семафор — это объект, над которым можно выполнить три операции:

1. Инициализация семафора (задать начальное значение счётчика)
2. Захват семафора (ждать пока счётчик станет больше 0, после этого уменьшить счётчик на единицу)
3. Освобождение семафора (увеличить счётчик на единицу)

Реализуется ОС, описан в POSIX, на базе семафора можно реализовать остальные механизмы синхронизации.

Мютексы (mutex)

```
#include <mutex>

std::mutex m;

m.lock();
m.unlock();

if (m.try_lock())
    m.unlock();
```

Мютексы (mutex)

```
int i = 0;

std::mutex mutex;

void plus1()
{
    std::lock_guard<std::mutex> lock(mutex);
    i += 1;
}

std::thread t1(plus1);
std::thread t2(plus1);
```

Мютексы (mutex)

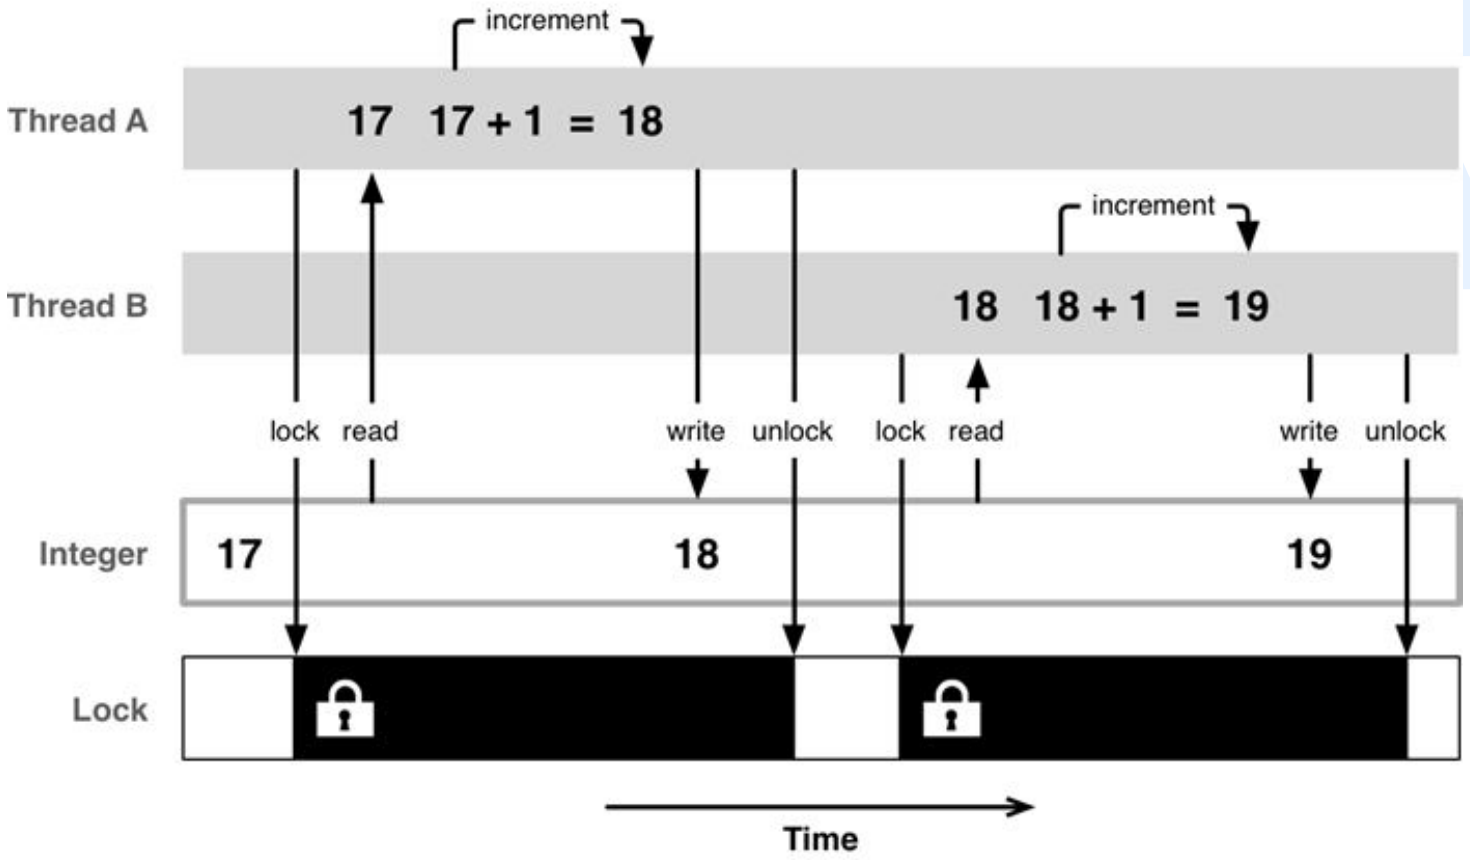

recursive_mutex

```
std::mutex m;
m.lock();
m.lock(); // Неопределенное поведение

std::recursive_mutex m;
m.lock();
m.lock(); // Ок
```

Количество lock и unlock должно совпадать

timed_mutex

```
#include <mutex>

std::timed_mutex m;

m.lock();
m.unlock();

if (m.try_lock())
    m.unlock();

auto period = std::chrono::milliseconds(100);
if (m.try_lock_for(period))
    m.unlock();

auto now = std::chrono::steady_clock::now();
m.try_lock_until(now + std::chrono::seconds(1));
```

shared_mutex C++14

Есть область памяти, позволяющая чтение и запись. Несколько потоков имеют к ней доступ, при этом одновременно могут читать сколько угодно потоков, но писать — только один. Как обеспечить такой режим доступа?

- **Приоритет читателя**
  Пока память открыта на чтение, давать читателям беспрепятственный доступ. Писатели могут ждать сколько угодно.
- **Приоритет писателя**
  Как только появился хоть один писатель, читателей больше не пускать. При этом читатели могут простаивать.
- **Одинаковый приоритет**
  Независимо от действий других потоков, читатель или писатель должен пройти барьер за конечное время

shared_mutex C++14

Класс `std::shared_mutex` - это примитив синхронизации, который может использоваться для защиты общих данных от одновременного доступа нескольких потоков. В отличие от других типов mutex, которые облегчают эксклюзивный доступ, shared_mutex имеет два уровня доступа:

- общий - несколько потоков могут совместно владеть одним и тем же mutex .
- эксклюзив - только один поток может владеть mutex.

shared_mutex C++14

```cpp
#include <shared_mutex>

std::shared_mutex mutex;

void reader()
{
    std::shared_lock<std::shared_mutex> lock(mutex);
    // блокируется если есть unique_lock
    // не блокируется, если есть другие shared_lock
}

void writer()
{
    std::unique_lock<std::shared_mutex> lock(mutex);
    // получить эксклюзивный доступ на общих условиях
}
```

Code time

- Пишем потокобезопасный кэш

Атомарные операции

std::atomic_flag

`std::atomic` атомарно изменяет значение, гарантия, что изменение не приводит к блокировке есть только у `std::atomic_flag`.

Класс `std::atomic_flag` предоставляет самый простой атомарный флаг. Это единственный тип данных, гарантированно свободный от блокировок согласно стандарту C++11. Экземпляр `std::atomic_flag` является либо установленным, либо сброшенным.

std::atomic_flag

```
// флаг сброшен
std::atomic_flag keepWorking = ATOMIC_FLAG_INIT;

// устанавливает флаг и возвращает предыдущее значение
keepWorking.test_and_set();

void threadFunc()
{
    while (keepWorking.test_and_set(std::memory_order_acquire)))
    {
    }
}

// сбросить флаг
keepWorking.clear(std::memory_order_release);
```

std::atomic<T>

```
std::atomic<int> i;

i.is_lock_free(); // true, если изменение не приводит к блокировке

i.store(5);

int j = i.exchange(7); // атомарно сохраняет новое значение и
возвращает предыдущее значение

int k = 7;

bool ok = i.compare_exchange_weak(k, 9);
// атомарно сравнивает значение с ожидаемым значением и сохраняет
// новое значение, если они равны друг другу и обновление можно
// выполнить атомарно
```

std::atomic<T>

```
ok = i.compare_exchange_strong(k, 9);
// аналогично compare_exchange_weak, но не бывает ложных срабатываний
// как если бы *this != expected

while (!i.compare_exchange_weak(k, 9)) ;
// compare_exchange_weak можно использовать в цикле, на некоторых
архитектурах
// это дает более эффективный код
```

std::atomic<T>

```
std::atomic<int> i;
int prev = i.fetch_add(5);

// fetch_sub
// fetch_and
// fetch_or
// fetch_xor
```

Взаимоблокировки (deadlock)

Взаимоблокировки (deadlock)

```
std::mutex m1;
std::mutex m2;

void t1() // thread 1
{
    std::lock_guard<std::mutex> lock1(m1);
    std::lock_guard<std::mutex> lock2(m2);
}

void t2() // thread 2
{
    std::lock_guard<std::mutex> lock1(m2);
    std::lock_guard<std::mutex> lock2(m1);
}
```

Блокировка в одном и том же порядке

```
void t1() // thread 1
{
    std::lock_guard<std::mutex> lock1(m1);
    std::lock_guard<std::mutex> lock2(m2);
}

void t2() // thread 2
{
    std::lock_guard<std::mutex> lock1(m1);
    std::lock_guard<std::mutex> lock2(m2);
}
```

Одновременная блокировка

Иногда дать гарантию на блокировку в одном и том же порядке дать нельзя.

```
class Data
{
    std::mutex m_;
public:
    void apply(const Data& data)
    {
        std::lock_guard<std::mutex> lock1(m_);
        std::lock_guard<std::mutex> lock2(data.m_);
        ...
    }
};
```

Одновременная блокировка

```
Data d1;
Data d2;

d1.apply(d2); // thread 1
d2.apply(d1); // thread 2

void apply(const Data& data)
{
    using Lock = std::unique_lock<std::mutex>;
    Lock lock1(m_, std::defer_lock);
    Lock lock2(data.m_, std::defer_lock);
    std::lock(lock1, lock2);
    ...
}
```

Условные переменные (condition_variable)

Средство для обеспечения коммуникации потоков.

```
Data data;

std::mutex m;
std::condition_variable dataReady;

void consumer() // thread 1
{
    std::unique_lock<std::mutex> lock(m);
    while (!data.ready())
        dataReady.wait(lock);
}
```

Условные переменные (condition_variable)

```
void producer() // thread 2
{
    {
        std::lock_guard<std::mutex> lock(m);
        data.prepare();
    }
    dataReady.notify_one();
}
```

Пул потоков (thread pool)

Создание потока – дорогая операция, поэтому иногда хочется этого избежать.

Идея:

1. Создаем N потоков, каждый поток либо выполняет задачу, либо спит;
2. Новая задача добавляется в очередь, при этом происходит оповещение спящих потоков;
3. Проснувшись поток проверяет, что в очереди есть задача, после чего извлекает её из очереди и выполняет;
4. Если задачи нет, поток засыпает, ожидая оповещения.

Домашнее задание

Домашнее задание #N

Да шучу я, шучу

Полезная литература в помощь

- Энтони Уильямс. C++. Практика многопоточного программирования

Напоминание оставить отзыв

Это правда важно

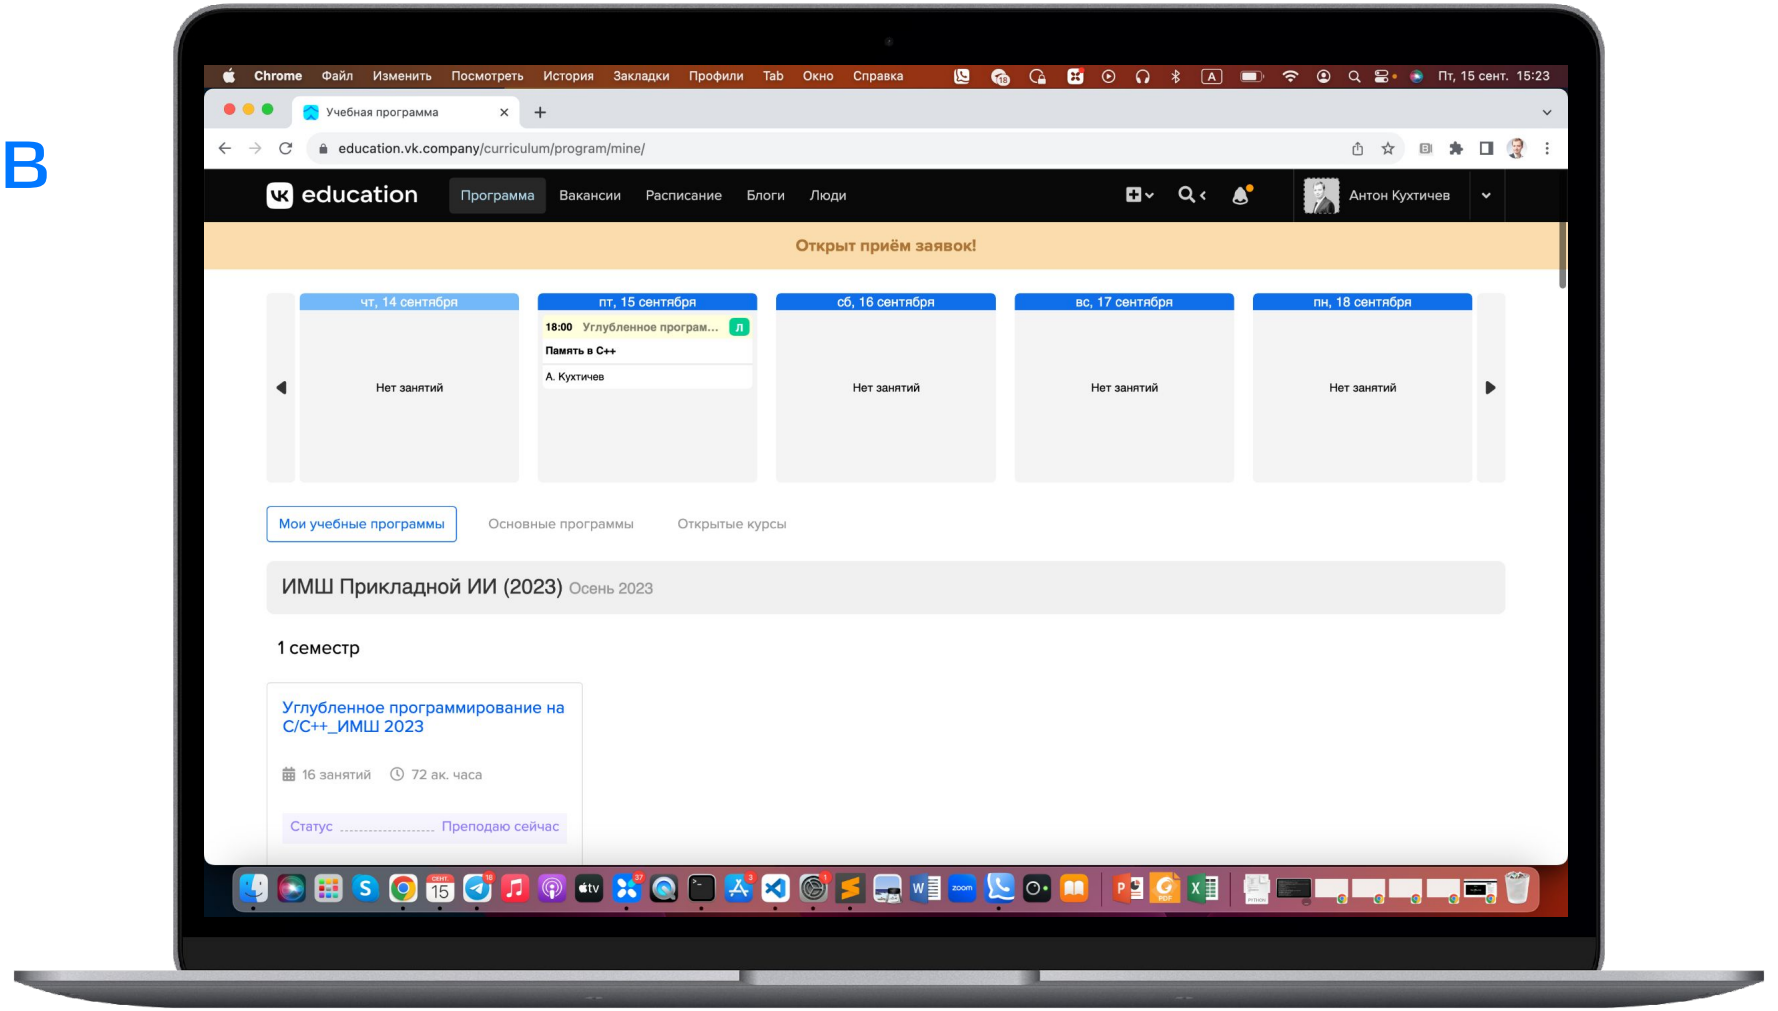

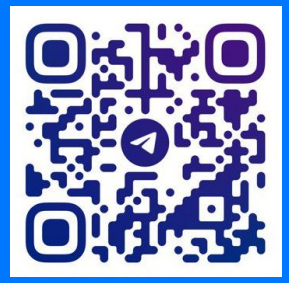

Спасибо
за внимание!